

1. Exploratory Data Analysis

- Proses Yang Dilakukan
Membersihkan baris data kosong pada fitur target (Nobeyesded), lalu saya juga membuat visualisasi data count plot yang digunakan untuk menampilkan jumlah atau frekuensi kemunculan data pada setiap variabel contohnya kelas obesitas, fitur angka obesitas, boxplot hubungan berat badan dengan tingkat obesitas, dan pengaruh konsumsi makanan tinggi kalori atau FAVC.
- Alasan Mengambil Keputusan Tersebut
Analisis ini digunakan untuk mengenali karakteristik sebaran data, mendeteksi potensi adanya imbalance class, serta melihat korelasi awal antara gaya hidup seperti kalori tinggi dan aktivitas fisik terhadap tingkat risiko obesitas pasien
- Interpretasi Hasil
Sebaran data kategori obesitas memiliki distribusi secara variatif dari insufficient weight hingga sampai obesity type iii, di mana bisa dilihat bahwa berat badan dan kebiasaan konsumsi kalori tinggi menunjukkan korelasi yang signifikan terhadap peningkatan risiko obesitas pada individu.
- Kodingan nya yang saya pakai untuk visualisasi distribusi kelas target adalah

```
import matplotlib.pyplot as plt
import seaborn as sns

# Visualisasi distribusi kelas target
plt.figure(figsize=(10, 5))
sns.countplot(data=df_clean, y='NObesyesdad', palette='viridis')
plt.title('Distribusi Tingkat Obesitas')
plt.show()
```

2. Data Preprocessing & Scikit-Learn Pipeline

- Proses yang dilakukan
Memisahkan fitur matriks (X) dan target (y), membagi data latih dan data uji train_test_split dengan adanya rasio sebesar 80:20, serta juga membuat Scikit-Learn Pipeline dengan menggabungkan StandardScaler untuk fitur numerik dan OneHotEncoder untuk fitur kategori
- Alasan Mengambil Keputusan Tersebut
Penggunaan pipeline dipilih agar seluruh aturan transformasi data terkunci rapi menjadi satu dengan model. StandardScaler digunakan agar fitur numerik dengan rentang nilai berbeda memiliki nilai yang sama, sementara OneHotEncoder dipilih untuk mengubah data teks kategori menjadi format biner agar dapat dipahami oleh algoritma di klasifikasi.
- Interpretasi Hasil
Adanya alur pemrosesan data yang konsisten. Hal ini dapat mencegah terjadinya data leakage sekaligus akan menjamin data mentah dari input pengguna di aplikasi web akan langsung melakukan tahapan pembersihan dan penskalaan sebelum diproses oleh model.

- Contoh Kodingan Untuk Preprocessor


```
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler

preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features),
        ('cat', OneHotEncoder(handle_unknown='ignore'), categorical_features),
    ]
)
```

3. Model Engineering & Selection

- Proses yang dilakukan
Melakukan eksperimen komparatif dengan menguji tiga model klasifikasi yang berbeda di dalam pipeline, yaitu baseline (K-Nearest Neighbors), Random Forest Classifier, dan juga Gradient Boosting Classifier.
- Alasan Pengambilan Keputusan
Pengujian beberapa algoritma dilakukan untuk membandingkan tingkat performa akurasi awal guna mencari arsitektur yang akan optimal dalam menangani kompleksitas data multikelas terhadap kesehatan pasien.
- Interpretasi Hasil
Algoritma berbasis ensemble atau sama seperti Random Forest dan Gradient Boosting mencatatkan tingkat akurasi yang lebih unggul dan stabil dibandingkan dengan model baseline (KNN), di mana random forest dipilih sebagai basis utama karena efisiensi dan ketahanan terhadap overfitting.
- Contoh Kodingan


```
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier

models = {
    'Baseline (KNN)': KNeighborsClassifier(n_neighbors=5),
    'Random Forest': RandomForestClassifier(random_state=42),
}
```

4. Validasi & Hyperparameter Tuning

- Proses yang dilakukan
Mengoptimalkan performa model Random Forest menggunakan metode GridSearchCV dengan validasi silang atau cross-validation-fold untuk mencari kombinasi parameter seperti `n_estimators`, `max_depth`, dan `min_samples_split`.
- Alasan Pengambilan Keputusan
Tuning parameter dilakukan untuk memaksimalkan generalisasi model pada data baru. Penyimpanan akan dilakukan ke `.pkl` files agar model yang benar dan yang sudah di train dapat langsung dimuat ke apk web puskesmas tanpa adanya pelatihan ulang, agar juga mengenal pola tersembunyi i dalam data dan membuat prediksi. Tanpa training, algoritma random forest hanya akan menjadi pohon kosong yang tidak ada kemampuan untuk membedakan faktor-faktor penyebab obesitas.
- Interpretasi Hasil
Memperoleh parameter optimal dengan `gridsearchcv` telah selesai menguji kombinasi model. Program berhasil menemukan kombinasi angka untuk `n_estimators` dan `max_depth`. Hal ini memperoleh skor validasi yang tinggi seperti data dibagi 5 bagian dan diuji secara bergantian, membuktikan bahwa model final tidak hanya latihan, tetapi benar-benar akurat saat melihat datanya
- Contoh Kodingan

```
from sklearn.model_selection import GridSearchCV
import joblib
```

```
rf_pipeline = Pipeline([
    ('preprocessor', preprocessor),
    ('classifier', RandomForestClassifier(random_state=42)),
])
grid_search = GridSearchCV(
    rf_pipeline,
    {'classifier__n_estimators': [50, 100]},
    cv=5,
    scoring='accuracy',
)
grid_search.fit(X_train, y_train)
joblib.dump(grid_search.best_estimator_, 'model_obesitas_terbaik.pkl')
```

5. Evaluasi Model

- Proses yang dilakukan
Menguji model terbaik untuk data pengujian pada X_{test} , serta mencetak laporan performa seperti precision, recall, f1-score, dan juga memvisualisasikan Confusion Matrix.
- Alasan pengambilan keputusan
Evaluasi ini digunakan untuk memastikan model tidak hanya unggul tetapi juga dapat mendiagnosis setiap kategori tingkat obesitas secara benar dan teliti.
- Interpretasi Hasil
Visualisasi pada Confusion Matrix menunjukkan bahwa sebagian besar sampel data terkonsentrasi pada bagian utama, menandakan bahwa ketepatan diagnosis klinis yang bagus.
- Contoh Kodingan:

```
from sklearn.metrics import classification_report
```

```
y_pred_best = best_model.predict(X_test)
print(classification_report(y_test, y_pred_best))
```

- Contoh Gambar:

Sistem Peringatan Dini Resiko Obesitas (Puskesmas)

Apakah berisiko & di dalam waktu seminggu hingga dua bulan kemudian mengalami tingkat kategori obesitas pasien berdasarkan ukuran tubuh dan kebiasaan gaya hidup?

Masukkan Data & Kebiasaan Pasien

Umur:

Jenis Kelamin:

Tinggi Badan:

Berat Badan:

Risiko Obesitas akan Muncul?

Peringkat Peringatan Dini Resiko:

Peringkat Risiko

Hasil Diagnosis Sistem:

Peringatan Dini Resiko Obesitas: Rendah. Disarankan untuk tidak melakukan pola makan yang berlebihan.